

Banco de Dados Vetorial: um guia direto

Um banco de dados vetorial armazena representações numéricas de textos, imagens ou audios chamadas de embeddings. Cada embedding é um vetor com centenas de dimensões que captura o significado do conteúdo original, de modo que itens parecidos ficam próximos no espaço vetorial e itens diferentes ficam distantes uns dos outros.

A busca nesse tipo de banco não procura palavras exatas, e sim vizinhança. Quando você faz uma pergunta, ela também vira um vetor e o banco devolve os trechos cujos vetores estão mais perto do vetor da pergunta. Essa proximidade costuma ser medida por similaridade de cosseno ou por distância euclidiana entre os pontos.

Para que a busca seja rápida mesmo com milhões de vetores, usa-se um índice aproximado como o HNSW. Em vez de comparar a consulta com todos os vetores, o índice navega por um grafo de poucos saltos e encontra vizinhos muito bons em tempo quase constante, trocando um pouco de precisão por uma enorme ganho de velocidade.

Antes de indexar, os documentos precisam ser quebrados em pedacos menores, os chamados chunks. O tamanho do chunk e o tamanho da sobreposicao entre eles influenciam diretamente a qualidade da recuperacao: chunks grandes preservam contexto, chunks pequenos recuperam com mais precisao, e a sobreposicao evita que uma ideia se perca bem na fronteira de dois pedacos.

Por fim, o banco vetorial raramente trabalha sozinho. Ele costuma fazer parte de um pipeline de RAG, onde os trechos recuperados são enviados como contexto para um modelo de linguagem gerar a resposta final. A qualidade do chunking, do embedding e do reordenamento define o teto de tudo o que vem depois nessa cadeia.